Politechnika Warszawska

WYDZIAŁ ELEKTRONIKI
I TECHNIK INFORMACYJNYCH

Instytut Informatyki

Sprawozdanie z realizacji projektu

Sumaryzacja tekstu

Tomasz Smoleń
Numer albumu

WARSZAWA 2026

Spis treści

1. Wstęp . . . 3
1.1. Opis i zilustrowanie problemu . . . 3
1.2. Motywacja . . . 3
1.3. Wkład własny . . . 3
1.3.1. Zbiór danych . . . 3
1.3.2. Przegląd pracy . . . 4
2. Przegląd literatury . . . 4
3. Opis rozwiązania . . . 5
3.1. Zbiór danych . . . 5
3.2. Użyte narzędzia i biblioteki . . . 5
3.3. Dostrajanie . . . 5
3.3.1. Few Shot . . . 5
3.3.2. LoRa . . . 6
4. Wyniki ewaluacji eksperymentalnej . . . 7
4.1. Sumaryzacja ekstrakcyjna . . . 7
4.2. Sumaryzacja abstrakcyjna . . . 8
4.2.1. Qwen 1.5 . . . 8
4.2.2. Qwen 2.5 . . . 8
4.2.3. Wielkie porównanie . . . 9
5. Podsumowanie . . . 9
5.1. Omówienie wyników . . . 9
5.2. Co można zrobić lepiej . . . 10
Bibliografia . . . 11

1. Wstęp

1.1. Opis i zilustrowanie problemu

Sumaryzacja tekstu polega na streszczaniu i podsumowywaniu tekstu. Może dotyczyć krótkich form (np. posty, listy), trochę dłuższych (np. artykuły) albo nawet całych książek. Tutaj skupimy się na sumaryzacji artykułów. Trudność sumaryzacji polega na wyekstraktowaniu najważniejszych cech oryginalnego tekstu i przekształcenie ich w krótszy, bardziej zwięzły tekst. Będziemy badać podejście ekstracyjne - czyli samo wybranie najważniejszych część tekstu (w tym przypadku zdań) oraz podejście abstrakcyjne - czyli wygenerowanie nowych zdań podsumuwujących oryginalny tekst.

1.2. Motywacja

Sumaryzacja tekstu to bardzo częste zastosowanie dla modeli językowych. Przykładowo, od niedawna przeglądając pliki tekstowe w Google Drive, obok tekstu pokaże się jego krótkie podsumowanie, dzięki któremu szybko się dowiemy czy znaleźliśmy odpowiedni plik. Podsumowania są też wykorzystywane przy indeksowaniu dokumentów, dzięki czemu możemy szukać interesujących nas artykułów nie tylko po tytule ale też po krótkim opisie treści. Współczesne przeglądarki internetowe też wykorzystują sumaryzację do tworzenia krótkich podsumowań pasujących do wyszukiwania artykułów i pokazania ich użytkownikowi, co może bardzo szybko odpowiedzieć na nasze pytanie bez potrzeby czytania każdego z artykułów w całości. Jednak ponieważ artykuły bądź inne teksty mogą być długie, i może być ich bardzo wiele, potrzebne są efektywne i szybkie sposoby sumaryzacji.

1.3. Wkład własny

1.3.1. Zbiór danych

Jako zbiór danych wykorzystano `EdinburghNLP/xsum`, który zawiera artykuły z gazet i ich podsumowania. Z powodu ograniczonych zasobów, wybrano tylko te dokumenty, które mają do 1500 znaków, jednak z powodu obszarności oryginalnego zbioru i tak otrzymaliśmy zbiór treningowy z ok. 85 tysiącami dokumentów i po 4.5 tysiąca w zbiorze walidacyjnym i testowym.

Przykład:

Artykuł:

> The crash happened about 07:20 GMT at the junction of the A127 and Progress Road in Leigh-on-Sea, Essex. The man, who police said is aged in his 20s, was treated at the scene for a head injury and suspected multiple fractures, the ambulance service said. He was airlifted to the Royal London Hospital for further treatment.

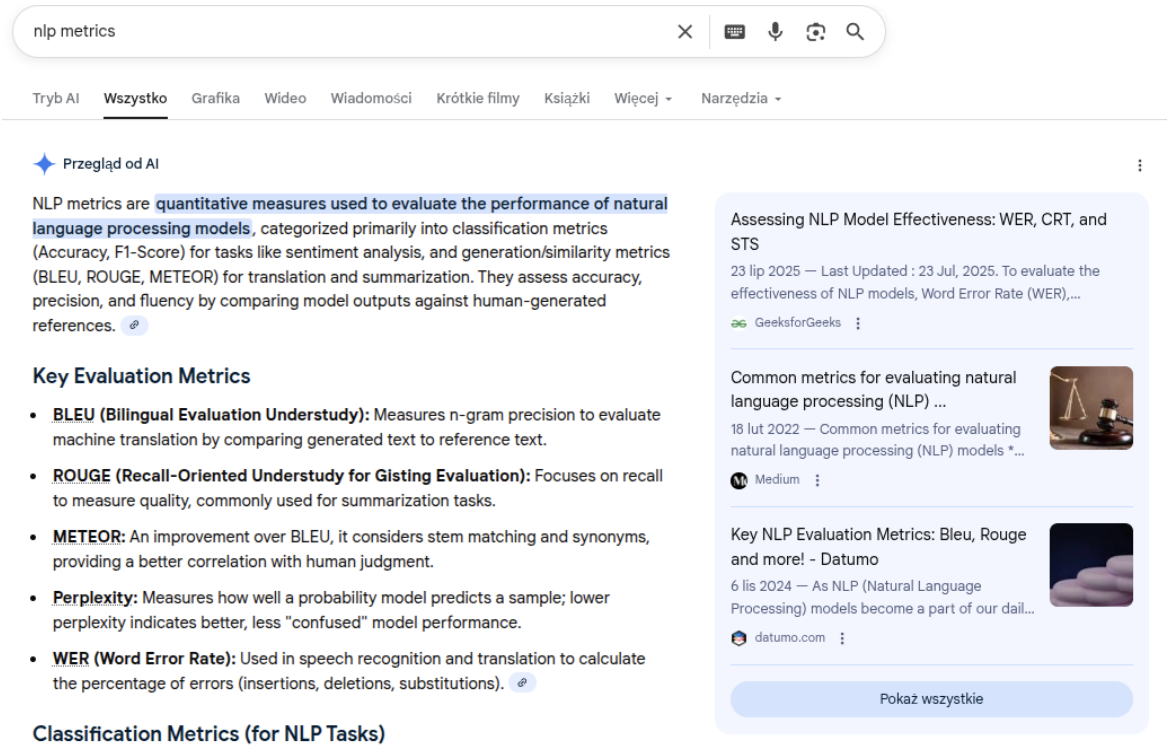

Rysunek 1.1. Sumaryzacja artykułów przy wyszukiwaniu w przeglądarce Google Chrome

The Southend-bound carriageway of the A127 was closed for about six hours while police conducted their initial inquiries. A spokeswoman for Essex Police said it was not possible comment to further as this time as the “investigation is now being conducted by the IPCC”.

Podsumowanie:

A jogger has been hit by an unmarked police car responding to an emergency call, leaving him with “serious life-changing injuries”.

1.3.2. Przegląd pracy

W ramach projektu dokonano porównania metody ekstracyjnej oraz metody abstrakcyjnej. Do metody ekstrakcyjnej użytko trzech różnych modeli z rodziny BERT. Do metody abstrakcynej użytko metod: zero oraz few shot prompting na dwóch modelach tylko dekoder. Dodatkowo użyto metody LoRa do zfinetunowania mniejszego z tych dwóch modeli.

2. Przegląd literatury

Do ewaluacji różnych podejść użyto metryki ROUGE opisanej w pracy [1], która skupia się na n-gramach pojawiających się w tekście wygenerowanym i referencyjnym.

Do sumaryzacji abstrakcynej wykorzystano modele z rodziny Qwen w wersji 1.5 [2], oraz 2.5 [3]

Do sumaryzacji ekstracyjnej użytko modele Bert base [4], Roberta base [5] oraz paraphrase-MiniLM-L6-v2 [6] z rodziny sentence-transformers.

3. Opis rozwiązania

3.1. Zbiór danych

Jak opisano wyżej zbiór danych został ograniczony do dokumentów mających do 1500 znaków. Z uwagi na dostępne zasoby ewaluacje wykonano na 500 dokumentach ze zbioru testowego po czym jako finalny wynik danego podejścia została wzięta średnia.

3.2. Użyte narzędzia i biblioteki

Do metryki Rouge użyto biblioteki Ignite. Do sumaryzacji ekstrakcynej użyto biblioteki bert-extractive-summarizer. Do finetuningu za pomocą LoRa oraz do inferencji użyto biblioteki Unsloth, która znacząco przyśpiesza oba procesy.

3.3. Dostrajanie

Dostrajane były modele w wersji base. Do dostrajnia modeli tylko dekoder użyto metod, zero-shot, few-shot oraz LoRa. Do wszystkich metod użyto tego samego początkowego promptu od użytkownika oraz szablonu czatu.

3.3.1. Few Shot

Metoda few-shot pobierała przykłady ze zbioru treningowego i pokazywała dokument oraz wymagane podsumowanie. Użyłem własnego uproszczonego szablonu czatu, który używa [USER], [TEXT] oraz [AGENT] oraz tokenu EOS z podanego tokenizatora, aby model nie generował kolejnych przykładów. Funkcja generująca przykłady: `generate_prompt()`

> [USER] Summarize this text. Don't hallucinate. Be thorough and explicit. Always provide an anwer.
>
> [TEXT]The 28-year-old and rowing partner Grainger, a 2012 gold medallist, compete in the women's double sculls heats at the European Championships. Thornley, from Wrexham, is confident of securing a place at Rio. "With it being Katherine's fifth Olympics there's no-one else you'd want sat behind you,"she said. "She knows how to handle pressure so well. Media playback is not supported on this device "I haven't won an Olympic medal and haven't had that feeling of being on an Olympic podium. "That, of course, is what I wake up to do every day and to achieve. That brings strengths into the boat from different sides."Grainger won gold in the double sculls at London 2012 with Anna Watkins after three consecutive Olympic silver

medals. The 40-year-old returned in September 2014 after a two-year sabbatical. She partners Thornley at the European Championships, which get under way in Brandenburg, Germany on Friday. "Obviously it's exciting, in Olympic year, to be selected for the first race of the year,"Thornley added. "But there's a long way to go in terms of sessions to do and days of training to do. "Every day I'm waking up and making sure I'm improving every single day. "Yes, we're looking to Rio but there's a lot of things to put in place before then. It's about keeping the focus on the here and now."

[AGENT]Victoria Thornley says her desire to emulate Olympic champion Katherine Grainger's achievements make them a force to be reckoned with.<|endoftext|>

[USER] Summarize this text. Don't hallucinate. Be thorough and explicit. Always provide an anwer.[TEXT] [tu wstawiany był dokument do podsumowania][AGENT][tutaj model mógł zacząć generację]

Użyto wersji z jednym oraz trzema przykładami. Większa ilość przykładów niestety wychodziła poza okno kontekstowe modelu i dawała niskie wyniki.

3.3.2. LoRa

Dostrajanie odbywało się w osobym pliku: `sft.py`. Dostrajano model Qwen1.5-0.5B z uwagi na jego bardzo mały rozmiar. Trening odbył się na 2000 krokach (parametr max steps) i trwał ok. 2 godziny. Do dostrajnia modeli tylko dekoder trzeba było złączyć kolumny w zbiorze danych zgodnie z szablonem, który będzie użyty do ewaluacji, wyglądającym tak samo jak przy metodzie few-shot powyżej, funkcja `merge_columns()`

Tabela 3.1. Proces treningu

Step	Training Loss	Validation Loss
200	2.320300	2.306880
400	2.303000	2.292080
600	2.292000	2.282069
800	2.285500	2.275186
1000	2.274300	2.269890
1200	2.279900	2.265329
1400	2.278100	2.261996
1600	2.269300	2.259525
1800	2.263800	2.257729
2000	2.257700	2.257052

4. Wyniki ewaluacji eksperymentalnej

Do ewaulacji użyto metryki Rouge w wariantach Rouge-1, Rouge-2 oraz Rouge-L.Rouge 1 i 2 porównują występujące w obu tekstach unigramy i bigramy, a Rouge-L najdłuższy wspólny ciąg słów. Dokładne sposoby wyliczania metryki Rouge są opisane w pracy [1].

Ewualuacje wykonano na 500 przykładach ze zbioru testowego.

4.1. Sumaryzacja ekstrakcyjna

Pomimo różnych architektur (BERT vs SBert) oraz różnych rozmiarów zbiorów treningowych i innych metod uczenia (BERT vs RoBERTa) wszystkie modele poradziły sobie praktycznie tak samo. Może to być kwestią tego, że wybranie +/- dwóch najważniejszych zdań z artykułu jest generalnie prostym zadaniem i wszystkie modele sobie z nim radzą, jednak jak się okaże później taki sposób sumaryzacji nie jest najlepszy.

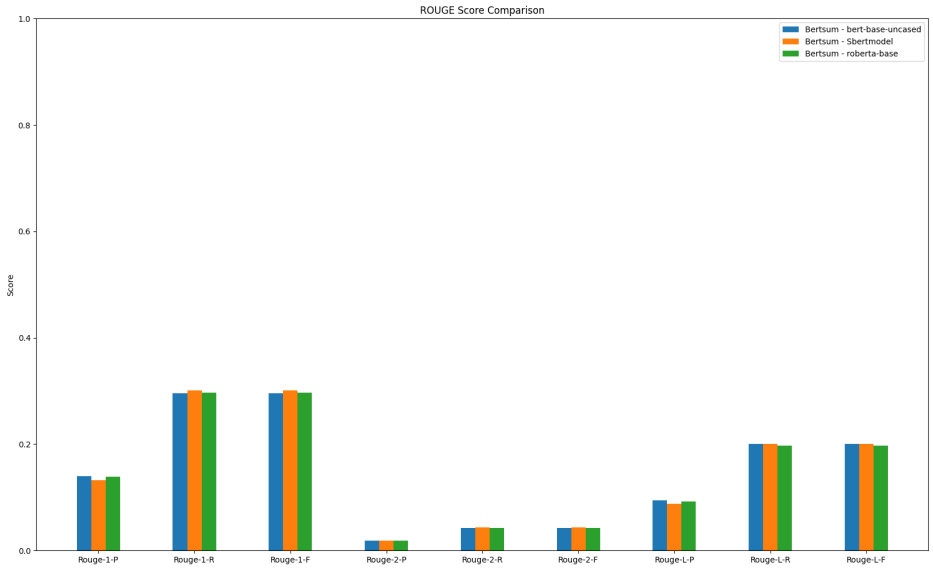

Rysunek 4.1. Porównanie różnych modeli tylko koder

Tabela 4.1. ROUGE Score Comparison

Model	ROUGE-1			ROUGE-2			ROUGE-L		
	P	R	F	P	R	F	P	R	F
BertSum – bert-base-uncased	**0.1396**	0.2958	0.2958	0.0191	0.0424	0.0424	**0.0940**	**0.2009**	**0.2009**
BertSum – Sbertmodel	0.1326	**0.3012**	**0.3012**	0.0185	**0.0436**	**0.0436**	0.0881	0.2008	0.2008
BertSum – roberta-base	0.1392	0.2963	0.2963	**0.0192**	0.0426	0.0426	0.0919	0.1970	0.1970

4.2. Sumaryzacja abstrakcyjna

Uwaga: w tej sekcji mowa o porównywaniu różnych "modeli". Oczywiście różne modele to tylko base vs chat/instruct, jednak w uproszczeniu dalej będę pisał o dostrajaniach zero-shot, one-shot itd. jako o różnych "modelach".

Do sumaryzacji abstrakcyjnej użyto modeli Qwen1.5 0.5B oraz Qwen2.5 3B w wersji base oraz chat/instruct. Modeli w wersji chat/instruct użyto jako punkt odniesienia i podano do nich ten sam prompt

4.2.1. Qwen 1.5

Wśród modeli z rodziny Qwen1.5 0.5B najlepiej poradził sobie model dostrojony metodą LoRa. Miał wyraźną przewagę we wszystkich kategoriach. Na drugim miejscu znalazły się na równi modele chat oraz three shot, potem z niewielką przewagą one shot i na końcu zero-shot.

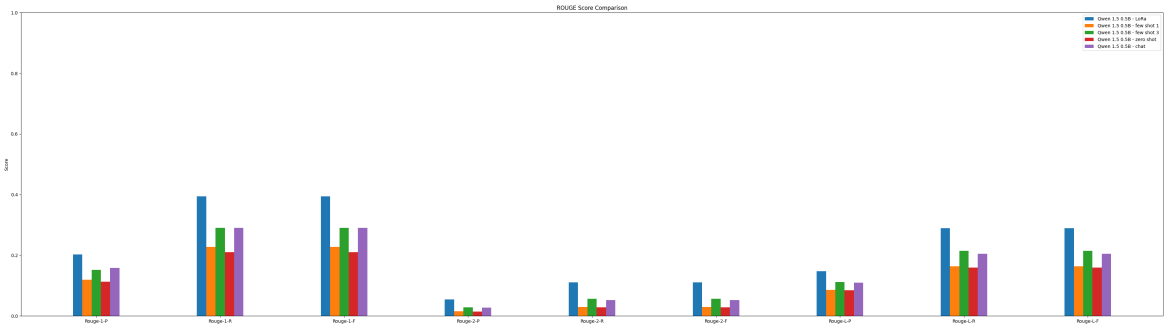

Rysunek 4.2. Porównanie modeli Qwen 1.5

Tabela 4.2. Qwen 1.5 rouge wyniki

Model	ROUGE-1			ROUGE-2			ROUGE-L		
	P	R	F	P	R	F	P	R	F
Qwen 1.5 0.5B – zero shot	0.1126	0.2098	0.2098	0.0148	0.0279	0.0279	0.0844	0.1590	0.1590
Qwen 1.5 0.5B – one shot	0.1197	0.2274	0.2274	0.0152	0.0300	0.0300	0.0853	0.1633	0.1633
Qwen 1.5 0.5B – three shot	0.1522	0.2901	0.2901	0.0287	0.0566	0.0566	0.1118	0.2142	0.2142
Qwen 1.5 0.5B – finetuned LoRa	**0.2024**	**0.3940**	**0.3940**	**0.0544**	**0.1111**	**0.1111**	**0.1474**	**0.2896**	**0.2896**
Qwen 1.5 0.5B – chat	0.1579	0.2908	0.2908	0.0272	0.0521	0.0521	0.1100	0.2050	0.2050

4.2.2. Qwen 2.5

Wśród modeli Qwen2.5 3B najlepiej poradził sobie zgodnie z oczekiwaniami three shot, potem one shot, na trzecim miejscu, ale niewiele w tyle instruct i na samym końcu zero shot. Ciekawe, że różnica pomiędzy modelem one-shot a zero-shot jest o wiele większa niż marginalna różnica w modelach Qwen1.5 0.5B. Dodatkowo one-shot poradził sobie w tym przypadku lepiej niż wersja instruct. Prawdopodobnie wynika to z większego rozmiaru i nowszej wersji modelu, która lepiej reaguje na sugestie i przykłady.

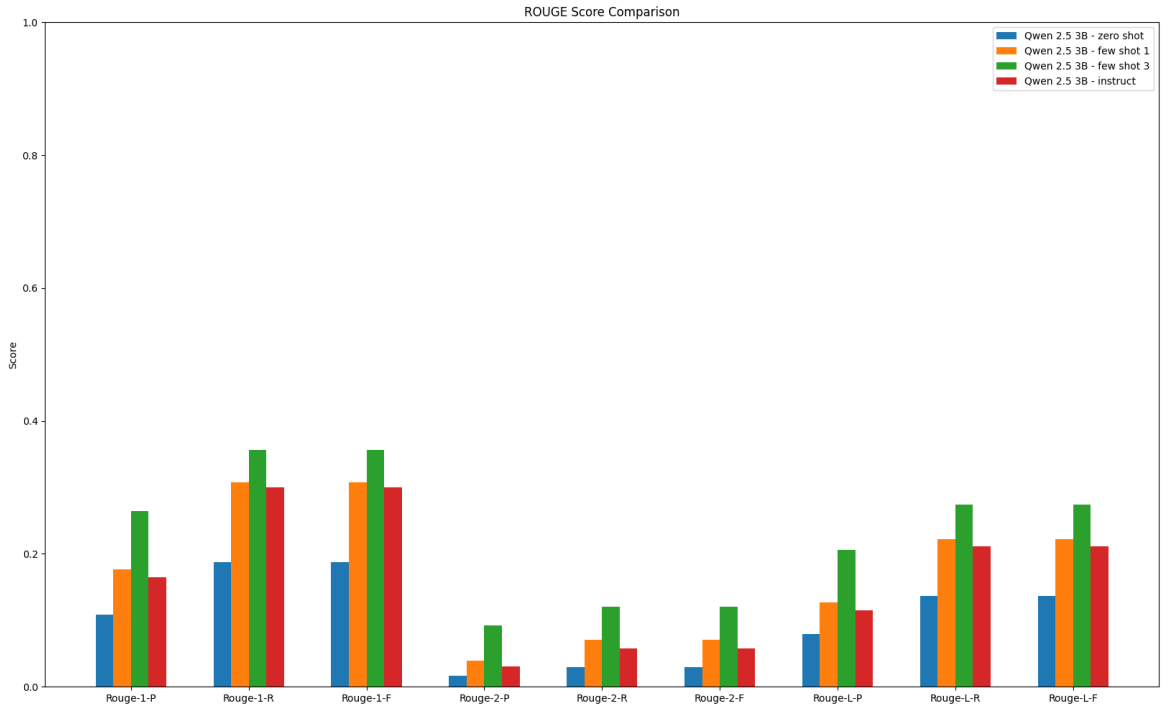

Rysunek 4.3. Porównanie modeli Qwen 2.5

Tabela 4.3. ROUGE Score Comparison – Qwen 2.5 3B

Model	ROUGE-1			ROUGE-2			ROUGE-L		
	P	R	F	P	R	F	P	R	F
Qwen 2.5 3B – zero shot	0.1086	0.1875	0.1875	0.0170	0.0296	0.0296	0.0795	0.1368	0.1368
Qwen 2.5 3B – one shot	0.1765	0.3076	0.3076	0.0387	0.0701	0.0701	0.1266	0.2219	0.2219
Qwen 2.5 3B – three shot	**0.2645**	**0.3561**	**0.3561**	**0.0926**	**0.1204**	**0.1204**	**0.2054**	**0.2739**	**0.2739**
Qwen 2.5 3B – instruct	0.1646	0.3004	0.3004	0.0307	0.0580	0.0580	0.1154	0.2119	0.2119

4.2.3. Wielkie porównanie

W tej sekcji zostanie omówione porównanie wszystkich powyższych wyników. Na wykresie, widać, że najlepiej spośród wszystkich podejść radzi sobie dostrojony Qwen1.5 0.5B oraz Qwen2.5 3B dostrojony metodą three-shot. Modele typu Bert, wszystkie poradziły sobie względnie dobrze jednak są wyraźnie w tyle za czołówką. Najgorzej zgodnie z oczekiwaniami poradził sobie Qwen 1.5 0.5B zero shot.

5. Podsumowanie

5.1. Omówienie wyników

Z wyników eksperymentów widać przewagę podejścia abstrakcyjnego od ekstrakcyjnego. Wynika to z tego, że wyciągnięcie +/- 2 zdań z tekstu nie wystarczy by przekazać najważniejszych w nich informacji, które są zawarte w całej szerokości tekstu. Nie da się

Tabela 4.4. ROUGE Score Comparison

Model		ROUGE-1			ROUGE-2			ROUGE-L		
		P	R	F	P	R	F	P	R	F
Qwen 1.5 0.5B	zero shot	0.1126	0.2098	0.2098	0.0148	0.0279	0.0279	0.0844	0.1590	0.1590
	one shot	0.1197	0.2274	0.2274	0.0152	0.0300	0.0300	0.0853	0.1633	0.1633
	three shot	0.1522	0.2901	0.2901	0.0287	0.0566	0.0566	0.1118	0.2142	0.2142
	LoRa	0.2024	**0.3940**	**0.3940**	0.0544	0.1111	0.1111	0.1474	**0.2896**	**0.2896**
	chat	0.1579	0.2908	0.2908	0.0272	0.0521	0.0521	0.1100	0.2050	0.2050
BertSum	bert-base-uncased	0.1396	0.2958	0.2958	0.0191	0.0424	0.0424	0.0940	0.2009	0.2009
	Sbertmodel	0.1326	0.3012	0.3012	0.0185	0.0436	0.0436	0.0881	0.2008	0.2008
	roberta-base	0.1392	0.2963	0.2963	0.0192	0.0426	0.0426	0.0919	0.1970	0.1970
Qwen 2.5 3B	zero shot	0.1086	0.1875	0.1875	0.0170	0.0296	0.0296	0.0795	0.1368	0.1368
	one shot	0.1765	0.3076	0.3076	0.0387	0.0701	0.0701	0.1266	0.2219	0.2219
	three shot	**0.2645**	0.3561	0.3561	**0.0926**	**0.1204**	**0.1204**	**0.2054**	0.2739	0.2739
	instruct	0.1646	0.3004	0.3004	0.0307	0.0580	0.0580	0.1154	0.2119	0.2119

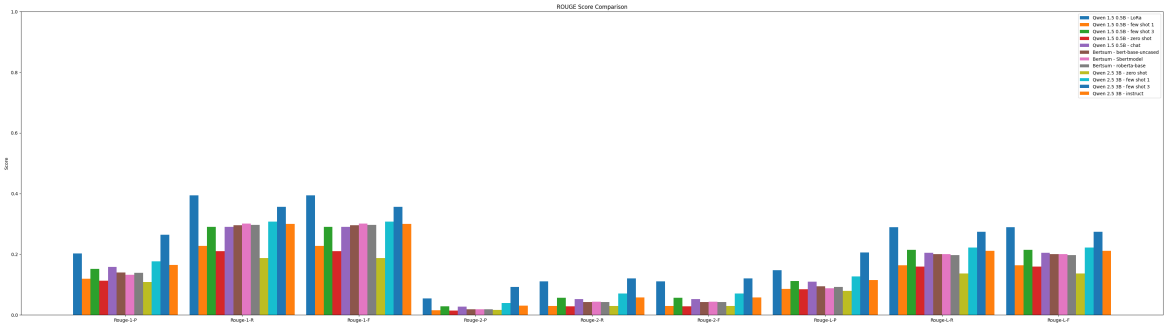

Rysunek 4.4. Wielkie porównanie

jednak odmówić koderom prędkości. Przebadanie ich działania zajmowało kilkadziesiąt razy mniej czasu. Lepsze wyniki odniosły jednak tylko-dekodery, które na bazie dosyć długiego tekstu potrafiły wygenerować sensowne podsumowanie. Największym zaskoczeniem badania jest wielki sukces, którym było dostrajanie modelu Qwen1.5 0.5B. Model ten radził sobie znacznie lepiej od np. wersji instruct modelu Qwen2.5 3B, który jest kilka razy większy i o rok nowszy. Pokazuje to skuteczność metody LoRa i jej potencjał do zastosowania w celach opisanych we wstępie. Jednak warto pamiętać, że nawet model Qwen1.5 0.5B dostrojony metodą three-shot, też tworzył sensowne podsumowania, a nie wymagał długiego treningu.

5.2. Co można zrobić lepiej

Niestety przez ograniczone zasoby sprzętowe musiałem badania przeprowadzać na bardzo małych modelach i ograniczonym zbiorze danych. Chętnie zobaczyłbym, czy dostrojanie za pomocą LoRa dałoby tak samo dobre wyniki w przypadku modeli o rozmiarach np. 7B oraz przy dłuższych tekstach. Ciekawe mogłoby być znalezienie "złotego środka modelu na tyle dużego, który by był bardziej odporny na halucynacje i niezawodny, a jednak na tyle małego, że można go by używać do szybkie podsumowywania setek dokumentów.

Bibliografia

[1] C.-Y. Lin, „Rouge: A package for automatic evaluation of summaries”, w *Text summarization branches out*, 2004, s. 74–81.

[2] J. Bai, S. Bai, Y. Chu i in., „Qwen Technical Report”, *arXiv preprint arXiv:2309.16609*, 2023.

[3] Q. Team, *Qwen2.5: A Party of Foundation Models*, wrz. 2024. adr.: `https://qwenlm.github.io/blog/qwen2.5/`.

[4] J. Devlin, M. Chang, K. Lee i K. Toutanova, „BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”, *CoRR*, t. abs/1810.04805, 2018. arXiv: `1810.04805`. adr.: `http://arxiv.org/abs/1810.04805`.

[5] Y. Liu, M. Ott, N. Goyal i in., „RoBERTa: A Robustly Optimized BERT Pretraining Approach”, *CoRR*, t. abs/1907.11692, 2019. arXiv: `1907.11692`. adr.: `http://arxiv.org/abs/1907.11692`.

[6] N. Reimers i I. Gurevych, „Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”, w *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, Association for Computational Linguistics, list. 2019. adr.: `http://arxiv.org/abs/1908.10084`.